

Clasificación de Imágenes de Quemaduras Usando Características Físicas y Redes Neuronales Convolucionales

J. A. Pérez-Carrasco, C. Serrano, B. Acha

Dpto de Teoría de la Señal y Comunicaciones, Universidad de Sevilla, Camino de los Descubrimientos, s/n. 41092, Sevilla España, {jperez2@us.es, bacha@us.es, cserrano@us.es}

Resumen

Este trabajo está enfocado en la clasificación de imágenes de quemaduras. Esta clasificación se realiza principalmente según la profundidad de las mismas. Sin embargo, la tasa de acierto en la determinación de estas quemaduras no es muy alta, con valores desde 50% en cirujanos inexpertos hasta 76% en cirujanos expertos. La determinación de la profundidad es crucial para determinar los primeros tratamientos para el paciente. Sin embargo, mantener una unidad de quemados es muy caro, con lo que sería muy útil y deseable disponer de un sistema automático de clasificación para ayudar durante las primeras evaluaciones en centros médicos o de urgencias, donde hay escasez de profesionales.

La clasificación de quemaduras se ha implementado considerando tres categorías: superficial (segundo grado superficial), profunda (segundo grado profunda) y de espesor total (tercer grado).

En el presente trabajo se han combinado características matemáticas, obtenidas a partir de características físicas de las quemaduras, con características obtenidas a partir de una red neuronal convolucional. La combinación de estas características ha sido utilizada para entrenar un clasificador SVM y, mediante un proceso de selección de características, se ha obtenido un conjunto reducido de características que proporciona los mejores resultados de clasificación. En particular, se ha obtenido una tasa de clasificación del 75% cuando la clasificación es en las tres categorías mencionadas, y un 88% cuando la clasificación se realiza en dos categorías: quemaduras que necesitan injertos y aquellas que no.

Las tasas de clasificación aportadas mejoran los resultados publicados en trabajos anteriores.

superficial pertenecen al primer grupo. Las de segundo grado profundo y tercer grado al segundo grupo.

Determinar la profundidad de una quemadura es un paso crucial y complicado [2][3]. Esta determinación se lleva a cabo a partir de información de color y textura principalmente. En los últimos años se han propuesto muchas herramientas de diagnóstico automático para asistir en la determinación de la profundidad [4-11], siendo las herramientas basadas en el uso de cámaras digitales las más interesantes debido al bajo precio [8-11].

En los trabajos de Acha y col., [10] y Serrano y col., [11] se determinaron características muy útiles analizando la información de color y textura de las quemaduras. Además, las técnicas de aprendizaje profundo (*deep learning*) y el uso de redes neuronales convolucionales están consiguiendo resultados muy prometedores en tareas de clasificación [12][13].

En este trabajo, diferentes características matemáticas obtenidas a partir de características físicas presentes en quemaduras [10][11] se han combinado con características proporcionadas por una red neuronal convolucional con la intención de proporcionar el conjunto de características más efectivo para implementar la clasificación de quemaduras. Además, se ha llevado a cabo un proceso de selección de características para reducir el número de características manteniendo la tasa de clasificación.

1. Motivación

Las heridas por quemadura tienen que ser diagnosticadas tan pronto como sea posible para proporcionar un primer tratamiento adecuado [1]. Cuando se diagnostica una quemadura, los principales factores que se tienen en cuenta son: profundidad, área quemada y localización. Las quemaduras se pueden clasificar en tres tipos principales: quemaduras de segundo grado superficial, quemaduras de segundo grado profundo (profundas) y quemaduras de tercer grado (espesor total). Las quemaduras de primer grado no han sido tenidas en cuenta porque normalmente son debidas al Sol y no suelen requerir intervención médica. Las quemaduras también se pueden clasificar en un conjunto de dos categorías: quemaduras que curan espontáneamente y que no necesitan injertos, y quemaduras que no curan por sí solas y que necesitan injertos. Las quemaduras de primer grado (debidas principalmente al Sol) y de segundo

2. Implementación

En el trabajo de Acha y col., [10] los autores analizaron las características físicas que los médicos y especialistas tienen en cuenta a la hora de evaluar una quemadura y trasladaron esas características físicas a características matemáticas que sí pueden ser clasificadas por un ordenador. Los autores proporcionaron un conjunto de ocho características (calculadas en los espacios RGB y La^*b^*). Estas características, que serán etiquetadas en este trabajo como *physical features*, son croma ($C_{a,b}^*$), valores extremos (*outliers*, o_{RGB}), tono (h), variación de tonalidad (v_{h^*}), asimetría de a^* (sk_{a^*}), asimetría de b^* (sk_{b^*}), medida de asimetría ($SK_{0.25}$) y curtosis de a^* (k_{a^*}). El cálculo de estas características y su significado físico se describen en detalle en [10].

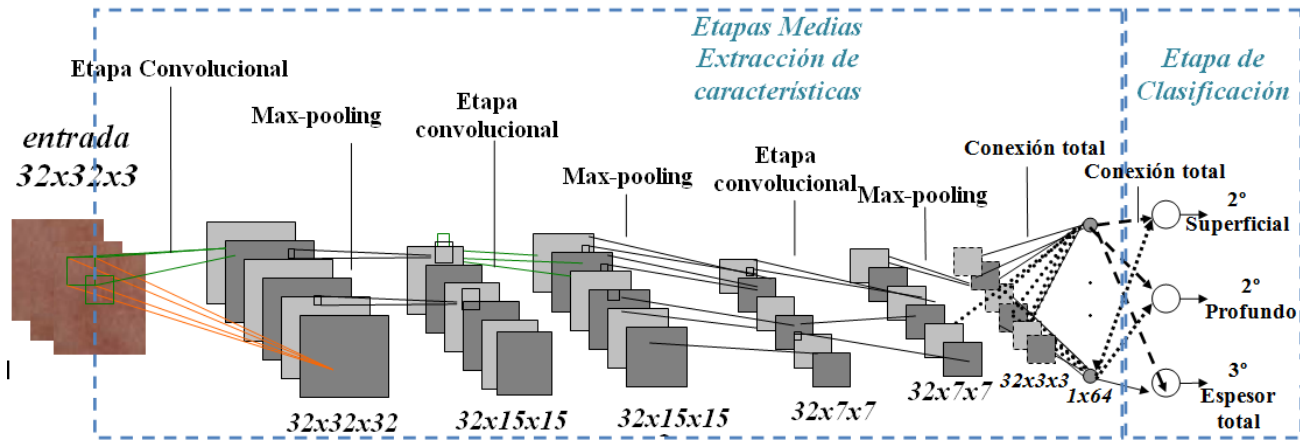


Figura 1. Red neuronal convolucional usada para la extracción de características y clasificación.

En la implementación desarrollada en este trabajo, el conjunto de características descrito es combinado con un segundo conjunto de características obtenidas a partir de una red neuronal convolucional (CNN). En particular, la red neuronal se ha obtenido adaptando la red neuronal convolucional (*cuda-convnet*) proporcionada por A. Krizhevsky [14]. La red utilizada se muestra en la Fig. 1 y recibe como entrada imágenes en color RGB de tamaño 32×32 .

La red está compuesta de tres etapas de operaciones de convolución y max-pooling (*maximo de agrupación*). Las salidas de cada etapa pasan a unidades lineales rectificadas (ReLU) para obtener no linealidad en el proceso. La primera etapa de convolución utiliza 3×32 filtros entrenables de tamaño 5×5 , proporcionando por tanto 32 imágenes de salida de tamaño 32×32 . La segunda etapa de convolución utiliza 32×32 filtros de tamaño 5×5 . La tercera etapa de convolución utiliza 32×64 filtros de tamaño 5×5 . Las últimas dos capas de la estructura son de conexión total. La última etapa implementa la clasificación y proporciona tres etiquetas de salida correspondientes a las tres categorías de quemaduras descritas. La entrada a esta última etapa de clasificación son vectores de tamaño 1×64 , correspondiendo por tanto a vectores de características 1×64 proporcionadas por la red.

En este artículo, la base de datos *Burns_BIP_US database* [15] ha sido utilizada en los experimentos. Esta base de datos fue utilizada en los trabajos de Acha y col., [10] y Serrano y col., [11] para clasificar imágenes de quemaduras. En la Fig. 2 se muestran algunas imágenes de esta base de datos. La red neuronal convolucional ha sido entrenada utilizando las 20 imágenes de quemaduras de entrenamiento de la base de datos. Como una arquitectura CNN necesita un gran número de imágenes para ser entrenada, y, en particular, la red descrita utiliza imágenes de color de tamaño 32×32 a la entrada, se obtuvieron 30 parches (en promedio) de tamaño 32×32 a partir de cada imagen de entrenamiento de la base de datos. Esto implica que la red CNN fue entrenada con un total de 6000 parches de color 32×32 . El conjunto de imágenes de test dentro de la base de datos está compuesto por 74 imágenes de quemaduras. De cada imagen de test se obtuvieron (de manera aleatoria) 4




Figura 2. Ejemplos de imágenes de quemaduras del conjunto de entrenamiento

parches de color 32×32 . Por tanto, el nuevo conjunto de datos de test está formado por 296 parches de color.

Una vez entrenada la red CNN, 20 parches de color 32×32 (un parche por cada imagen de entrenamiento original) pertenecientes al conjunto de entrenamiento y 296 parches del conjunto de test fueron procesados por la red CNN para obtener los correspondientes vectores de características (de tamaño 1×64) a la entrada de la última etapa de clasificación de la red neuronal (salida de las *Etapas Medias* en la Fig. 1).

Este conjunto de características, que será denotado como *cnn_features*, está compuesto por tanto por 316 vectores de características de tamaño 1×64 . De ellos, 20 corresponden al conjunto de entrenamiento y 296 al conjunto de test.

Las 8 características físicas descritas previamente y denotadas por *physical_features* fueron calculadas también

para cada uno de los 316 parches de color. Finalmente, el conjunto de 20 características físicas de entrenamiento (de tamaño 20x8) es combinado con el conjunto de 20x64 características $cn_{features}$ para construir un nuevo conjunto de características de entrenamiento de tamaño 20x72. Igual ocurre para el conjunto de test. Los 296 vectores de características $physical_{features}$ se combinaron con el conjunto de 296 $cn_{features}$ cada uno de tamaño 1x64 para crear un nuevo conjunto de 296 vectores de características de test de tamaño 296x72. La estrategia seguida para la combinación de estas características se detalla en la Fig. 3.

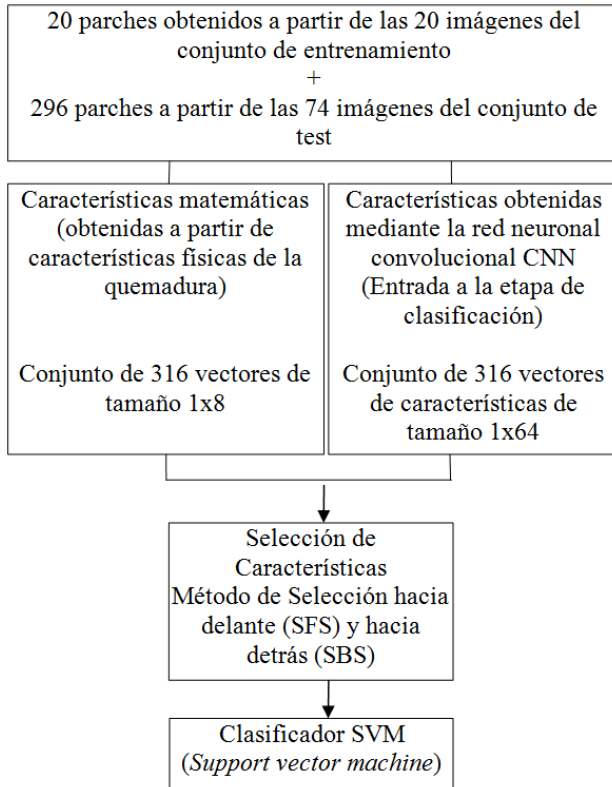


Figura 3. Diagrama de flujo del algoritmo empleado para clasificación

La clasificación en tres categorías de las imágenes de quemaduras es implementada en la última etapa del algoritmo mediante un clasificador SVM [16]. Para evitar problemas de sobreajuste (*overfitting*) se llevó a cabo una tarea de selección de características. Para ello, se emplearon las técnicas de selección de características hacia delante y hacia detrás (*SFS* y *SBS* respectivamente) para determinar qué características de las 72 seleccionadas (8 características físicas y 64 de la red CNN) eran las más discriminativas en la tarea de clasificación [10][11]. En primer lugar, y haciendo uso de las 72 características numéricas, el clasificador SVM y la técnica de selección de características hacia delante fueron empleados. Para ello la técnica de selección empezó con una sola característica y fue añadiendo características hasta obtener el conjunto de características que proporcionaba mejor resultado de clasificación. A continuación el proceso se repitió utilizando la técnica de selección hacia detrás y empezando con las 72

características. En cada iteración se eliminaban aquellas que no mejoraban el resultado clasificatorio. El proceso terminaba cuando se obtenía el conjunto de características que proporcionaba el mejor resultado en la clasificación. Finalmente, los dos conjuntos de características obtenidas mediante *SFS* y *SBS* fueron agrupados y la técnica de selección hacia detrás permitió obtener el conjunto final más reducido de características con los mejores resultados de clasificación.

Utilizando el conjunto de 20x72 vectores de características de entrenamiento y el conjunto de 296x72 vectores de características de test, las características que proporcionaban los mejores resultados en la clasificación en 3 categorías fueron:

$$fts_{3cat}=[C_{a*b*} \ h \ sk_b* \ cn_{features}(13) \ cn_{features}(34) \ cn_{features}(39)] \quad (1)$$

La clasificación en 2 categorías (quemaduras que requieren injertos y quemaduras que no lo requieren) fue implementada repitiendo todo el proceso descrito anteriormente. El conjunto de características obtenido en este caso fue:

$$fts_{2categories}=[C_{a*b*} \ sk_b* \ cn_{features}(39) \ cn_{features}(44) \ cn_{features}(58)] \quad (2)$$

3. Resultados Experimentales

En este apartado se muestran los resultados de clasificación en dos y tres categorías utilizando un clasificador SVM. Además, en la clasificación en dos categorías, se llevó a cabo un análisis de falsos positivos (FP), verdaderos positivos (TP), falsos negativos (FN) y verdaderos negativos (TN). Los verdaderos positivos (TP) corresponden a imágenes clasificadas correctamente como "necesita injerto". Falsos positivos (FP) son aquellas imágenes clasificadas por el algoritmo como "necesita injerto" cuando realmente son superficiales (no necesita injerto). Los falsos negativos (FN) corresponden a quemaduras clasificadas por el algoritmo como superficiales cuando en realidad son quemaduras de segundo grado profundo o tercer grado y finalmente, los verdaderos negativos (TN) corresponden a quemaduras clasificadas correctamente como "no necesita injerto".

Los resultados, que han sido obtenidos utilizando la misma base de datos [15] usada en los trabajos realizados por Acha y col., [10] y Serrano y col., [11], se muestran en la Tabla 1. Como se puede observar en la tabla, los resultados mejoran aquéllos proporcionados en [10][11]. Más específicamente, con la implementación descrita en este trabajo, la tasa de clasificación en tres categorías es de 75% (66.2% en el trabajo de Acha y col., [10]) y de 88.2% cuando la clasificación es en 2 categorías (82.4% en el trabajo de Acha y col., [10] y 79.73% en el trabajo de Serrano y col., [11]).

	Tasa de Clasificación	Acha y col. [10]	Serrano y col. [11]
Clasificación en 3 categorías	75%	66.2%	--
Clasificación en 2 categorías	88.2%	82.4%	79.73%
Verdaderos Positivos	145	31	38
Falsos Positivos	24	5	14
Falsos Negativos	11	8	1
Verdaderos Negativos	116	30	21
Sensibilidad (S)	0.936	0.80	0.97
Especificidad (E)	0.814	0.86	0.60
PPV	0.849	0.86	0.73
NPV	0.919	0.79	0.95

Tabla 1. Resultados de Clasificación

4. Conclusiones

La determinación de la profundidad de una quemadura es crucial en el diagnóstico de la misma y para proporcionar el tratamiento correspondiente más adecuado. En este trabajo se presenta una estrategia que combina características matemáticas obtenidas a partir de características físicas de las quemaduras y características obtenidas a través de una red neuronal convolucional. La combinación de tales características junto con el uso de un clasificador SVM mejoran los resultados de clasificación en comparación a los resultados que se obtendrían si se usaran los dos conjuntos de características por separado sin la combinación efectuada. Además, el algoritmo mejora los resultados publicados anteriormente, proporcionando tasas de clasificación de 75% cuando la clasificación se realiza en 3 categorías y de 88.2% cuando la clasificación se realiza en dos categorías.

En trabajos futuros se tratará de analizar el significado físico de las características extraídas por la red neuronal con la intención de optimizar la arquitectura de la misma.

Agradecimientos

El trabajo ha sido cofinanciado a través de los proyectos P11-TIC-7727, (Junta de Andalucía) y DPI2016-81103-R (Ministerio de Economía y Competitividad, Gobierno de España, Plan Retos, 2013-2016).

Referencias

- [1] Atiyeh BS, Gunn SW, Hayek SN. State of the art in burn treatment. *World J Surg*, vol. 29, 2005, pp 131-48 (ISSN: 0364-2313).
- [2] Roa LM, Gómez-Cía T, Acha B, Serrano C. Digital imaging in remote diagnosis of burns. *Burns*, vol. 25, sup 7, 1999, pp 617-24 (ISSN: 0305-4179).
- [3] Hlava P, Moserova J, Konigova R. Validity of clinical assessment of the depth of a thermal injury. *Acta Chir Plast*, vol. 25, 1983, pp 202-8 (ISSN: 0001-5423).
- [4] Rangayyan RM. Biomedical image analysis. CRC Press, 2005 (ISBN: 9780849396953).
- [5] Doi K. Computer-aided diagnosis in medical imaging. Historical review, current status and future potential. *Comput Med Imaging Graphics*, vol 31, sup 4-5, 2007, pp 198-211 (ISSN: 0895-6111).
- [6] Tylman W, Janicki M, Napieralski A. Automatisation of computer-aided burn wounds evaluation. *Proceedings of Int. Conf. Mixed Design of Integrated Circuits and Systems (MIXDES'12)*, Warsaw, 2012, pp 535-538 (ISBN: 9781457720925).
- [7] Yeong EK, Hsiao TC, Chiang HK, Lin CW. Prediction of burn healing time using artificial neural networks and reflectance spectrometer. *Burns*, vol 31, 2005, pp 415-20 (ISSN: 0305-4179).
- [8] Acha B, Serrano C, Acha JI, Roa LM. Segmentation and classification of burn images by color and texture information. *J Biomed Opt*, vol 10, sup 3, 2005, pp 1-11 (ISSN: 1083-3668).
- [9] Kaartinen IS, Valisuo PO, Alander JT, Kuokkanen HO. Objective scar assessment-a new method using standardized digital imaging and spectral modelling. *Burns*, vol 37, sup 1, 2011, pp 74-81 (ISSN: 0305-4179).
- [10] Acha B, Serrano C, Fondón I, Gómez-Cía T. Burn depth analysis using multidimensional Scaling applied to psychophysical experiment data. *IEEE Trans. Med Imaging*, vol 32, sup 6, 2013, pp 1111-20 (ISSN: 0278-0062).
- [11] Serrano C, Boloix-Tortosa R, Gómez-Cía T, Acha B. Features identification for automatic burn classification. *Burns*, vol 41, 2015, pp 1883-1890 (ISSN: 0305-4179).
- [12] Gonzalez RC, Woods RE. Digital image processing. third ed. Prentice Hall, 2008 (ISBN: 013168728X).
- [13] Tran HS, Le TH, Nguyen TT. The Degree of Skin Burns Images Recognition using Convolutional Neural Network. *Indian Journal of Science and Technology*, vol 9, sup 45, 2016, pp 1-6 (ISSN: 0974-6846).
- [14] Página web de Krizhevsky A: cuda-convnet code. <https://code.google.com/archive/p/cuda-convnet/> (Consultada: Septiembre 2017).
- [15] Página web de base de datos Burns_BIP_US database. http://personal.us.es/rboloix/Burns_BIP_US_database.zip (Consultada: Septiembre 2017).
- [16] Cortes C, Vapnik V. Support-vector networks. *Machine Learning*, vol 20, sup 3, 1995, pp 273-97 (ISSN: 1573-0565).