

Detección e identificación de vértebras en imágenes de TC empleando técnicas de inteligencia artificial y procesamiento de imagen

A. Jiménez-Pastor¹, A. Alberich-Bayarri^{1,2}, B. Fos-Guarinos¹, F. García-Castro¹, L. Martí-Bonmatí^{1,2}

¹ Quibim, Quantitative Imaging Biomarkers in Medicine, Valencia, España

² GIBI2³⁰, Instituto de Investigación Sanitaria La Fe, Valencia, España

Resumen

Detectar e identificar las vértebras en una imagen radiológica es muy importante a la hora de diagnosticar o realizar el seguimiento de los procesos patológicos de la columna vertebral. Actualmente el radiólogo realiza esta tarea de forma manual, limitando la eficiencia de su flujo de trabajo. Por todo esto, resulta de gran interés diseñar un sistema de ayuda al diagnóstico que automáticamente detecte e identifique todas aquellas vértebras que se encuentren en una imagen, ayudando a una caracterización automática de la estructura ósea vertebral y a una disminución de los tiempos de informado. En el presente trabajo se propone un algoritmo que detecta e identifica automáticamente las vértebras en imágenes de Tomografía Computarizada (TC) independientemente de cuál sea la cobertura anatómica de la imagen o de si se trata de un caso sano o patológico. Para el desarrollo del algoritmo se propone el uso combinado de técnicas de procesamiento de imagen, con técnicas de aprendizaje máquina como las Redes Neuronales Convolucionales. Este algoritmo se ha desarrollado empleando una base de datos de 232 imágenes de TC toraco-abdomino-pélvicas. Se ha obtenido un error de localización de 7.98 ± 8.73 mm y una tasa de identificación del 90.43%. Este algoritmo proporciona un nuevo método para detectar e identificar automáticamente las vértebras en imágenes de TC de cobertura arbitraria.

1. Introducción

La correcta detección e identificación de las vértebras es muy importante a la hora de diagnosticar o realizar el seguimiento de los pacientes que padecen alguna patología en la columna vertebral, e.g. osteoporosis, escoliosis, cifosis. Actualmente, la identificación de las vértebras en una imagen médica la debe realizar el radiólogo manualmente, siendo una tarea temporalmente costosa y laboriosa para el especialista, ralentizado su flujo de trabajo.

Los principales problemas que se presentan a la hora de realizar un algoritmo que permita detectar e identificar automáticamente las vértebras en una imagen de Tomografía Computarizada (TC) son la arbitrariedad en la cobertura de la imagen, es decir, en cada adquisición la región anatómica visible es diferente. La similitud que presentan las vértebras entre sí es alta. La presencia de implantes metálicos que generen artefactos en la imagen, o la presencia de distintas patologías.

En los últimos años, los algoritmos basados en Inteligencia Artificial (IA) han sido de gran utilidad para abordar este tipo de problemas, permitiendo detectar y segmentar automáticamente estructuras anatómicas en las imágenes radiológicas, acelerando el diagnóstico y ayudando a la integración de métodos cuantitativos para la extracción de biomarcadores de imagen [1-3]. Concretamente, para la detección e identificación automática de cuerpos vertebrales en imágenes de Tomografía Computarizada (TC) se han empleado distintas técnicas de IA, como son los árboles de decisión [4-6] y las redes neuronales [7,8].

En el presente proyecto se plantea una metodología basada en redes neuronales, en concreto, en redes neuronales convolucionales (CNN: *Convolutional Neural Networks*) con el objetivo de detectar en una imagen médica las distintas regiones anatómicas, junto con técnicas de procesamiento de imagen, como son la umbralización o la dilatación, con el objetivo de detectar la posición de la línea central de la columna vertebral.

2. Objetivos

El principal objetivo del presente trabajo es el desarrollo de un algoritmo que permita la detección e identificación automática de vértebras en imágenes de TC independientemente de la cobertura de la misma o de si existen implantes metálicos o algún proceso patológico. Con todo esto se podrán generar flujos que permitan la caracterización automática de la estructura del hueso, y reducir el tiempo de diagnóstico.

3. Materiales

El presente trabajo se desarrolló utilizando Matlab R2016a (Mathworks Inc, Natick, MA, USA) como entorno de programación.

3.1. Bases de datos empleadas

Se realizó una recopilación retrospectiva de 230 estudios de TC comprendiendo distintas coberturas a lo largo del eje z (dirección longitudinal al paciente). Para enriquecer la base de datos, esta debía contener, a su vez, tanto estudios sanos como patológicos.

Todas estas imágenes se etiquetaron manualmente seleccionando el centroide de cada una de las vértebras visibles, almacenando para cada etiqueta $v = \{T1, \dots, T12, L1, \dots, L5, S1\}$ sus coordenadas absolutas, considerando

un total de 18 etiquetas que comprenden las 12 vértebras torácicas, las 5 lumbares y la primera sacra. Para llevar a cabo este etiquetado de la manera más eficiente posible, se diseñó un interfaz de usuario en la que el experto únicamente tenía que seleccionar, empleando las vistas coronal y sagital, la posición de cada uno de los centroides de las vértebras presentes y, automáticamente, estas posiciones quedaban guardadas en un archivo de texto.

Todas estas imágenes se dividieron en 2 grupos: el 80% para entrenar las redes y el 20% para testearlas.

4. Métodos

Para conseguir el objetivo final de la detección e identificación automática de vértebras, se dividió el proceso en distintos pasos.

En primer lugar, se localizó la posición de la línea media de la columna vertebral mediante la detección del canal medular. A continuación, dentro de esta línea media se localizaron los centroides de cada una de las vértebras empleando una serie de clasificadores basados en CNN.

4.1. Detección de la línea media de la columna vertebral

La localización de la columna vertebral se basa en la localización del canal medular y en un posterior desplazamiento.

Para poder detectar el canal medular (Figura 1) se realizó, en primer lugar, una umbralización binaria a 200 UH (*Unidades Hounsfield*) para quedarnos, principalmente, con aquellos píxeles de la imagen que pertenecen a hueso. A continuación, sobre la máscara anterior, se realizó una dilatación empleando un elemento estructural cilíndrico con un radio de 3mm y una altura de 10mm, con lo cual se consiguió potenciar la característica de que el canal medular se encuentra rodeado de hueso cortical. Finalmente, se realizó una operación NOT, se eliminaron todos aquellos píxeles en contacto con los extremos de la imagen y se eliminaron todos aquellos objetos con un área menor de 500mm³.

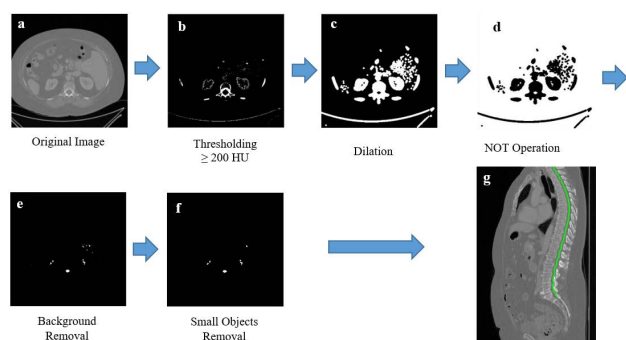


Figura 1. Proceso de detección del canal medular

Una vez detectada la línea central del canal medular, ésta se desplazó en sentido postero-anterior 2cm (distancia aproximada del canal medular a centro de la vértebra) con el objetivo de situar esta línea en el centro de la columna vertebral.

4.2. Detección e identificación de los centroides de las vértebras

Una vez tenemos detectada la columna vertebral, el objetivo es detectar e identificar cada una de las vértebras que la componen. Este proceso (Figura 2) se dividió a su vez en distintos pasos. En primer lugar, se dividió la imagen en distintas regiones: torácica superior, torácica inferior, lumbar y sacra, posteriormente, dentro de cada región, se detectaron aquellos cortes transversales en los que predominaba la presencia de vértebra frente a la presencia de disco intervertebral. A continuación, se calcularon los centroides de cada vértebra. Finalmente, sabiendo a que región pertenecían estos centroides, se realizó la identificación de los mismos.




Figura 2. Proceso de detección e identificación de los centroides de cada una de las vértebras presentes en una imagen

Detección regiones

Para dividir una imagen en las distintas regiones (Figura 3) que la componen se realizó la clasificación de cada uno de los cortes transversales que forman la imagen en 5 grupos distintos: 1, si pertenecen a la región torácica superior; 2, si pertenecen a la región torácica inferior; 3, si pertenecen a la región lumbar; 4, si pertenecen a la región sacra; y 0, si no pertenece a ninguna de estas regiones.




Figura 3. Detección regiones

El clasificador empleado está formado en primer lugar por una CNN pre-entrenada, concretamente *Alexnet* [9], encargada de extraer características de la imagen, seguido de un clasificador SVM (*Support Vector Machine*) binario.

Este se entrenó empleando 1.809 imágenes de cada clase, de cada una de las cuales se extrajeron 4.096 características.

Detección vértebras

Una vez teníamos la imagen dividida por regiones, se emplearon dos clasificadores más, basados también en una CNN pre-entrenada seguida de un clasificador binario SVM. Para aquellos cortes pertenecientes a las regiones torácica superior y torácica inferior se empleó un clasificador que dividiera las imágenes en dos grupos distintos: 1, vértebra; y 0, no vértebra, dependiendo de si en estas predomina la presencia de vértebra o de disco intervertebral respectivamente. Para entrenar este clasificador se emplearon 3.986 imágenes de cada clase.

Para aquellos cortes pertenecientes a las regiones lumbar y sacra se empleó un clasificador con la misma estructura que el anterior. Para entrenar este clasificador se emplearon 1.763 imágenes de cada clase. El resultado obtenido tras aplicar estos clasificadores en una imagen de test se puede observar en la Figura 4




Figura 4.Detección vértebras

Calculo centroides e identificación

Finalmente, para el cálculo de los centroides (Figura 5), se calculó el punto medio de cada segmento detectado como vértebra.




Figura 5.Cálculo centroides

Una vez los centroides de cada una de las vértebras presentes en la imagen estaban detectados y se sabía a qué región pertenecían, con una serie de operaciones lógicas se realizó su identificación (Figura 6).




Figura 6.Identificación centroides

5. Resultados y discusión

Para analizar los resultados obtenidos se calculó el error de localización para cada una de las vértebras, el cual se define como la distancia entre la posición del centroide estimado y la real, así como la tasa de identificación. Se considera que una vértebra está correctamente identificada si la distancia entre el centroide estimado y el real es menor de 2cm [5].

	Mediana (mm)	Media (mm)	STD (mm)	TASA ID.
Todas	4.91	7.98	8.73	90.43%
Torácicas	4.12	7.37	8.69	89.20%
Lumbares	6.42	9.21	8.70	92.90%

Tabla 1. Mediana, media y desviación típica del error de localización y tasa de identificación por regiones

En la Tabla 1 se puede observar el error de localización y la tasa de identificación obtenidos para cada una de las regiones. Se puede apreciar que en la región torácica el error de localización obtenido (7.37 ± 8.69 mm) es menor que el obtenido para la región lumbar (9.21 ± 8.70 mm). Sin embargo, vemos que la región lumbar, pese a tener un error de localización mayor, presenta una tasa de identificación mayor (92.90%) que la región torácica (89.20%).

Estos resultados mejoran los obtenidos utilizando la metodología de bosques de decisión, objeto de una publicación reciente por nuestro grupo y en el que se obtuvo un error de localización de 13.73 ± 10.32 mm y tasa de identificación de 77.99%, empleando el mismo dataset que en la presente metodología.

6. Conclusión

Las técnicas de inteligencia artificial permiten detectar e identificar automáticamente las vértebras en imágenes de TC. En concreto, las CNN han demostrado ser útiles para extraer características complejas que permitan clasificar una imagen radiológica en las distintas categorías. Además, al combinar éstas con técnicas de procesamiento de imagen, que permitan detectar la línea central de la columna vertebral, obtenemos un resultado satisfactorio en la detección e identificación de las vértebras.

Referencias

- [1] Criminisi, A., Robertson, D., Konukoglu, E., Shotton, J., Pathak, S., White, S., & Siddiqui, K. (2013). Regression forests for efficient anatomy detection and localization in computed tomography scans. *Medical image analysis*, 17(8), 1293-1303.
- [2] Lu F, Wu F, Hu P, Peng Z, Kong D. Automatic 3D liver location and segmentation via convolutional neural network and graph cut. *International Journal of Computer Assisted Radiology and Surgery*. 2016;12(2):171-182.
- [3] Hu P, Wu F, Peng J, Bao Y, Chen F, Kong D. Automatic abdominal multi-organ segmentation using deep convolutional neural network and time-implicit level sets. *International Journal of Computer Assisted Radiology and Surgery*. 2016;12(3):399-411.
- [4] Glocker B, Feulner J, Criminisi A, Haynor D, Konukoglu E. Automatic Localization and Identification of Vertebrae in Arbitrary Field-of-View CT Scans. *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2012*. 2012;;590-598.
- [5] Glocker B, Zikic D, Konukoglu E, Haynor D, Criminisi A. Vertebrae Localization in Pathological Spine CT via Dense

Classification from Sparse Annotations. *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2013*. 2013;;262-270.

- [6] Chu C, Belavý D, Armbrrecht G, Bansmann M, Felsenberg D, Zheng G. Fully Automatic Localization and Segmentation of 3D Vertebral Bodies from CT/MR Images via a Learning-Based Method. *PLOS ONE*. 2015;10(11):e0143327.
- [7] Suzani A, Seitel A, Liu Y, Fels S, Rohling R, Abolmaesumi P. Fast Automatic Vertebrae Detection and Localization in Pathological CT Scans - A Deep Learning Approach. *Lecture Notes in Computer Science*. 2015;;678-686.
- [8] Chen H, Shen C, Qin J, Ni D, Shi L, Cheng J et al. Automatic Localization and Identification of Vertebrae in Spine CT via a Joint Learning Model with Deep Neural Networks. *Lecture Notes in Computer Science*. 2015;;515-522.
- [9] Krizhevsky A, Sutskever I, Hinton G. ImageNet classification with deep convolutional neural networks. *Communications of the ACM*. 2017;60(6):84-90.